Flight Delay Prediction

Прогнозирование задержки авиарейсов

Исходный датасет	5 819 079 × 31
Train / Test	681 978 / 151 588
Целевая переменная	Задержка >= 15 мин

Целью проекта является построение модели, которая по информации, доступной до вылета, оценивает вероятность задержки рейса на 15 и более минут. Основное внимание уделено временной природе данных и дисбалансу классов.

Данные очищены от признаков, которые становятся известны после вылета, выполнен EDA, добавлены временные и агрегированные признаки, сравнены линейные модели, бустинг и MLP, для LightGBM и CatBoost выполнен подбор гиперпараметров с Optuna. Дополнительно проверены blending и stacking.

LightGBM дал лучший ROC-AUC на тесте, а SVM – практически лучший PR-AUC. Более сложный stacking не улучшил качество на будущем периоде.

Исходный датасет содержит 5,8 млн наблюдений. Для снижения вычислительной нагрузки исследование ограничено 15 наиболее загруженными аэропортами. После исключения отменённых и перенаправленных рейсов, а также строк без DEPARTURE_DELAY, осталось около 800000 наблюдений.

Далее данные разделены по времени: январь-сентябрь использованы для обучения, ноябрь-декабрь – как независимый тестовый период. Октябрь в исходном подмножестве отсутствовал. После формирования target из набора признаков удалены причины задержек и другие признаки, недоступные в момент прогноза.

EDA (Exploratory Data Analysis)

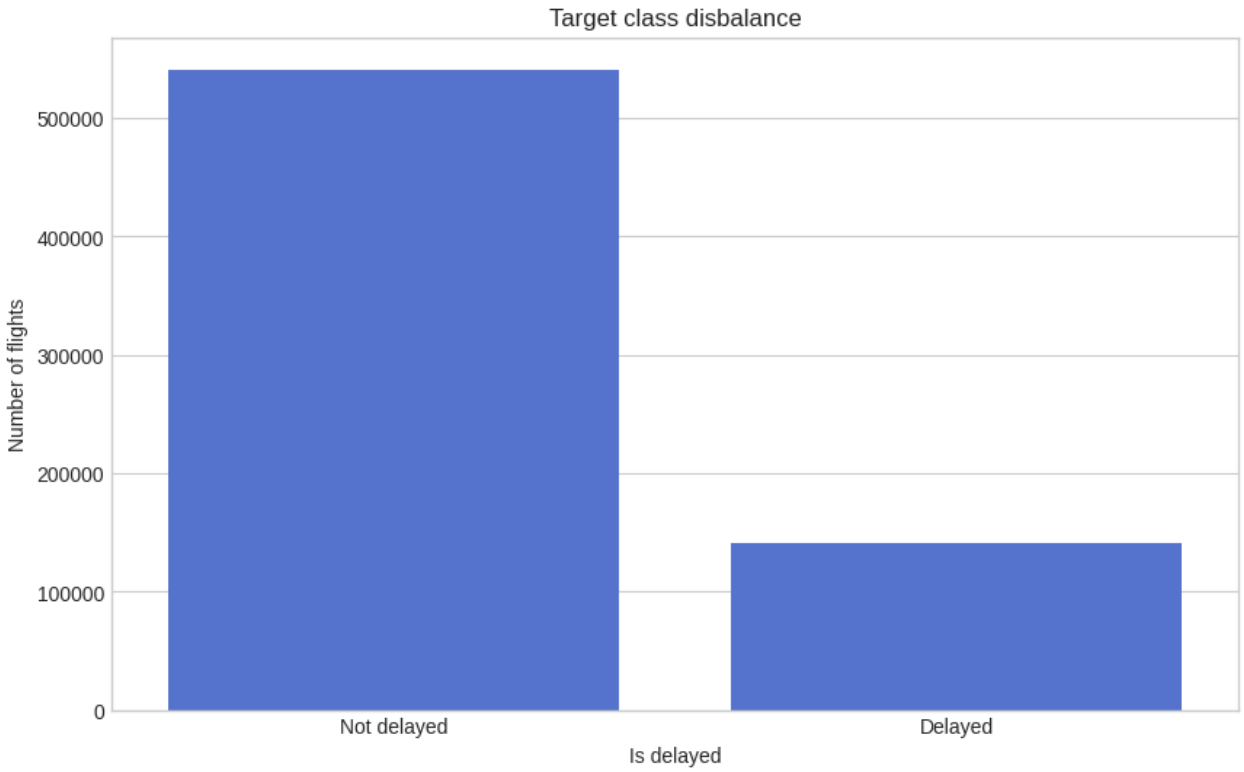


Рис. 1 – Дисбаланс классов на тренировочных данных

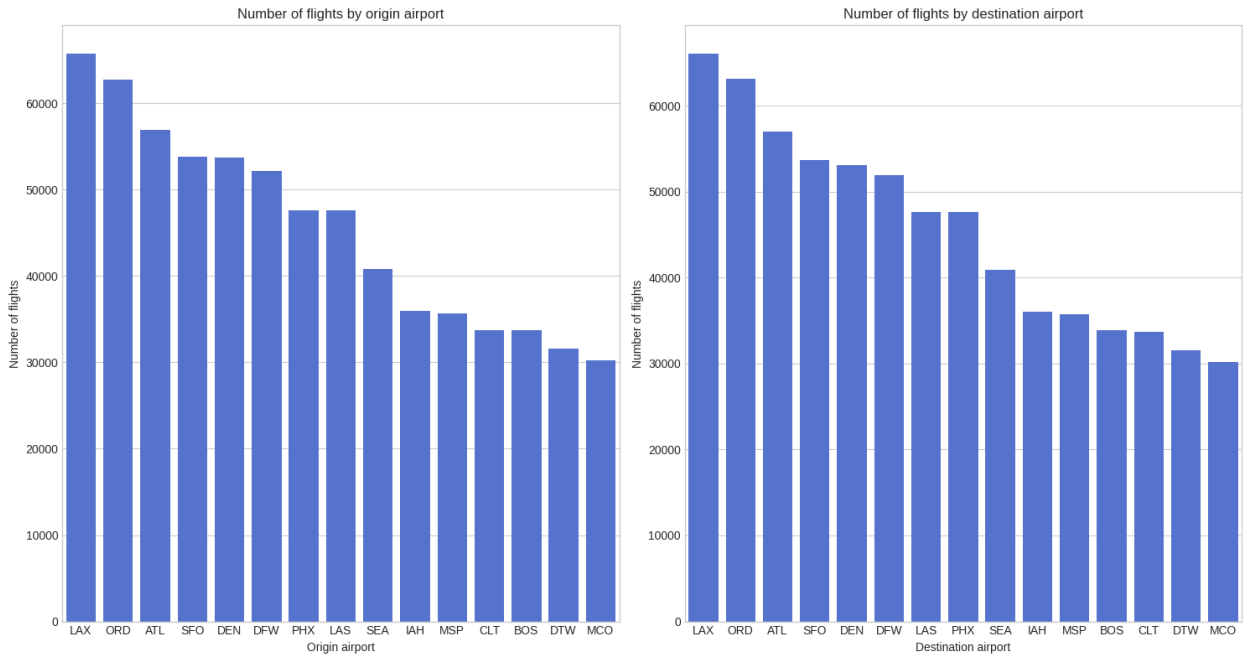


Рис. 2 – Количество полётов по каждому аэропорту

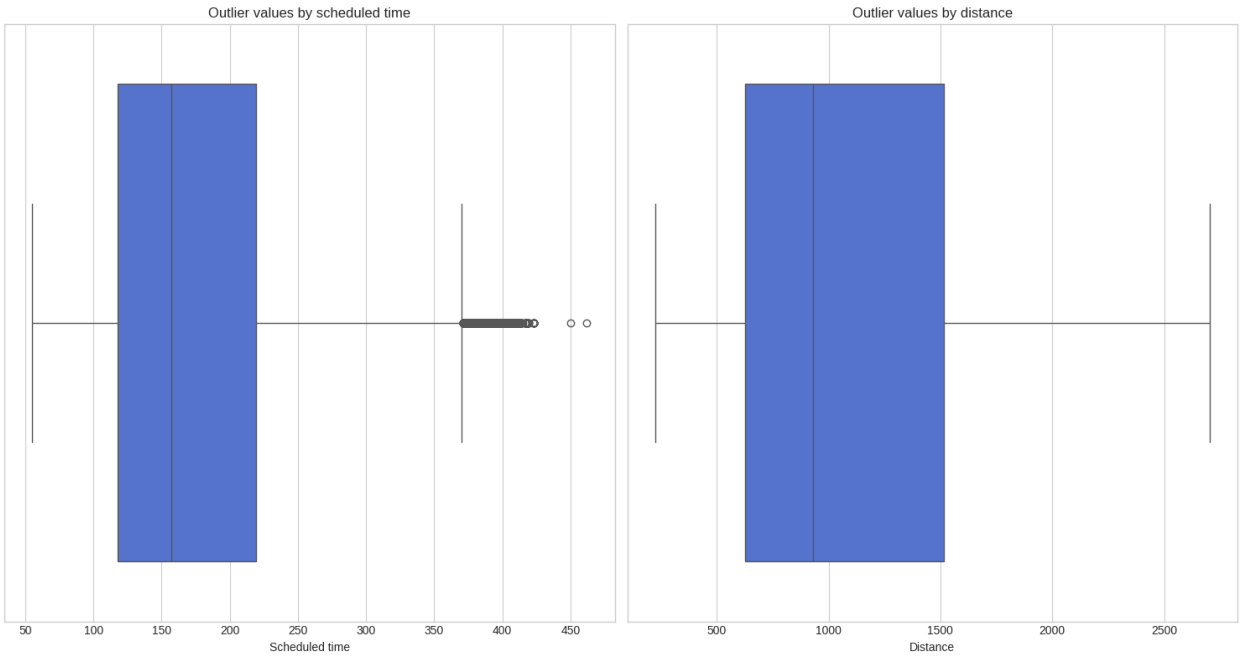


Рис. 3 – Выбросы по времени полёта и дистанции



Рис. 4 – Матрица корреляций для числовых признаков

Baseline models, ablation study, tuning, stacking

Для сравнения использовалась временная кросс-валидация TimeSeriesSplit с 5 folds. В каждом fold preprocessing (scaling и OHE) обучался только на train-части соответствующего fold, после чего применялся к validation-части.

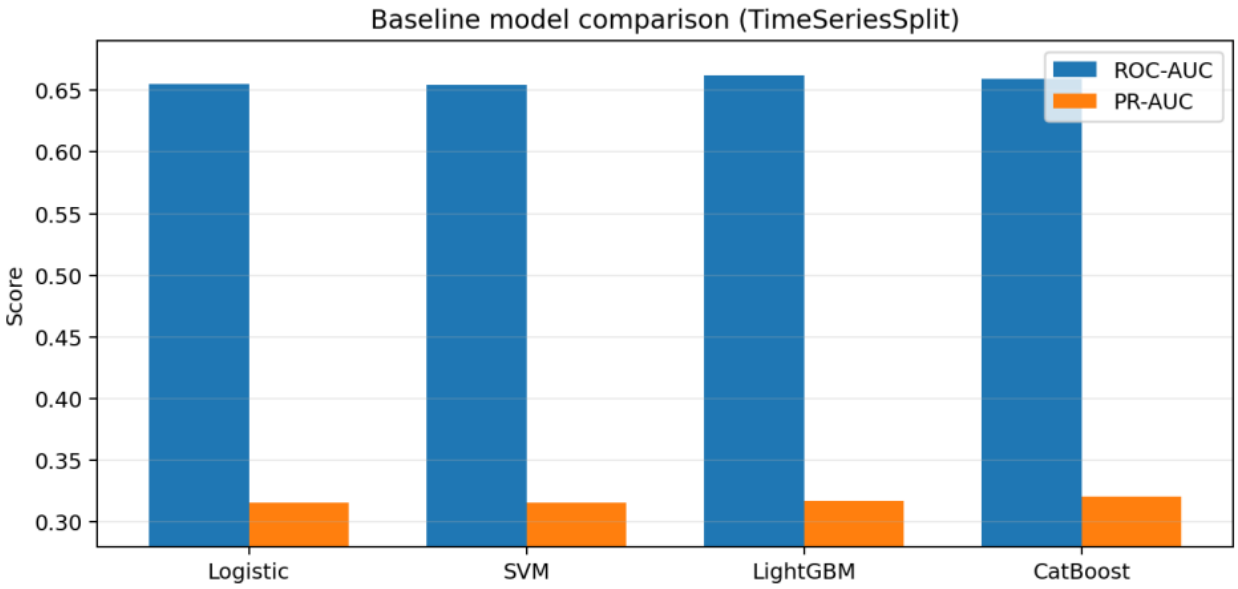


Рис. 5 – Сравнение базовых моделей по ROC-AUC и PR-AUC на временной кросс-валидации

Ablation study: удаление SCHEDULED_TIME практически не изменило качество. Добавление высококардинального TAIL_NUMBER также не дало устойчивого прироста. Поэтому для дальнейшей оптимизации выбран компактный конфиг без этих двух признаков.

После улучшения LightGBM и CatBoost остаются очень близкими по качеству – 0.664690 / 0.326780 (ROC-AUC / PR-AUC) для CatBoost и 0.662530 / 0.323900 (ROC-AUC / PR-AUC) для LGBM соответственно.

Дополнительно были построены blending 50/50 и stacking LightGBM + CatBoost с Logistic Regression в качестве мета-модели. На OOF-предсказаниях stacking дал небольшой прирост, однако на тестовом периоде преимущества не сохранились.

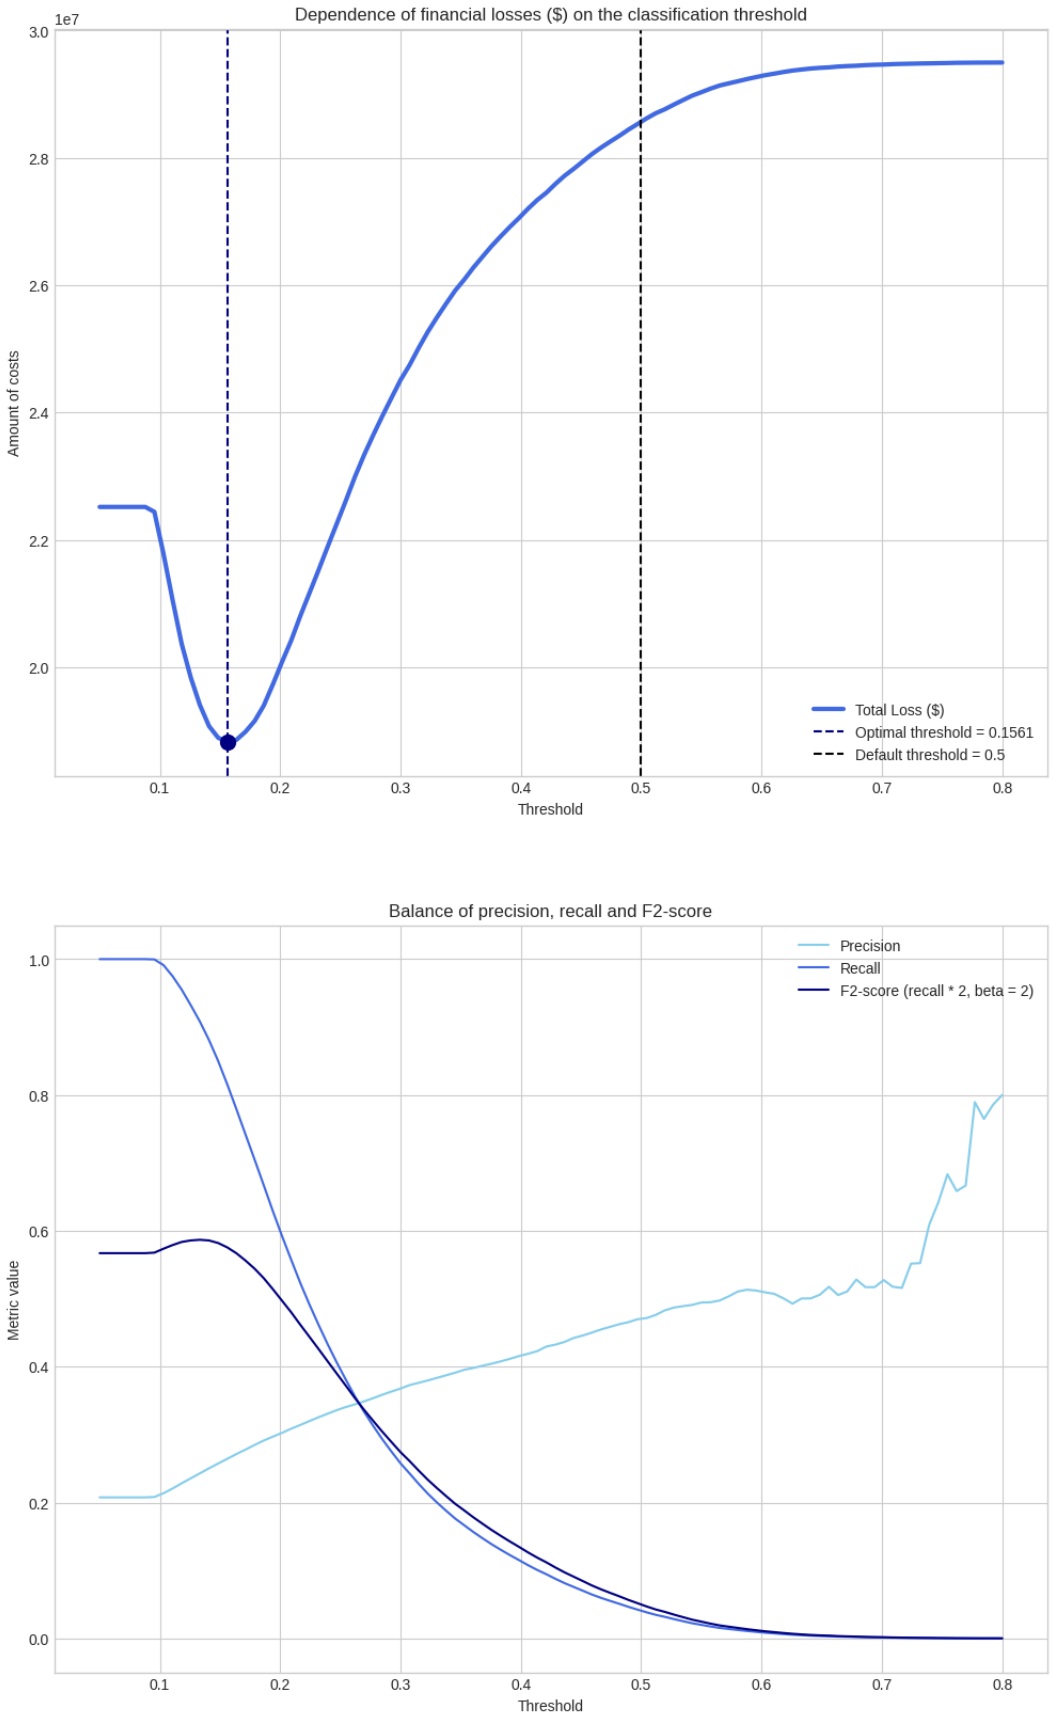


Рис. 6 – Зависимость стоимости ошибок и Precision/Recall от порога классификации

MLP

MLP реализован как отдельная нелинейная модель. Архитектура: входной слой --> 128 --> 64 --> 32 --> 1. После скрытых слоёв используются LayerNorm, ReLU и Dropout (0.3, 0.2 и 0.1).

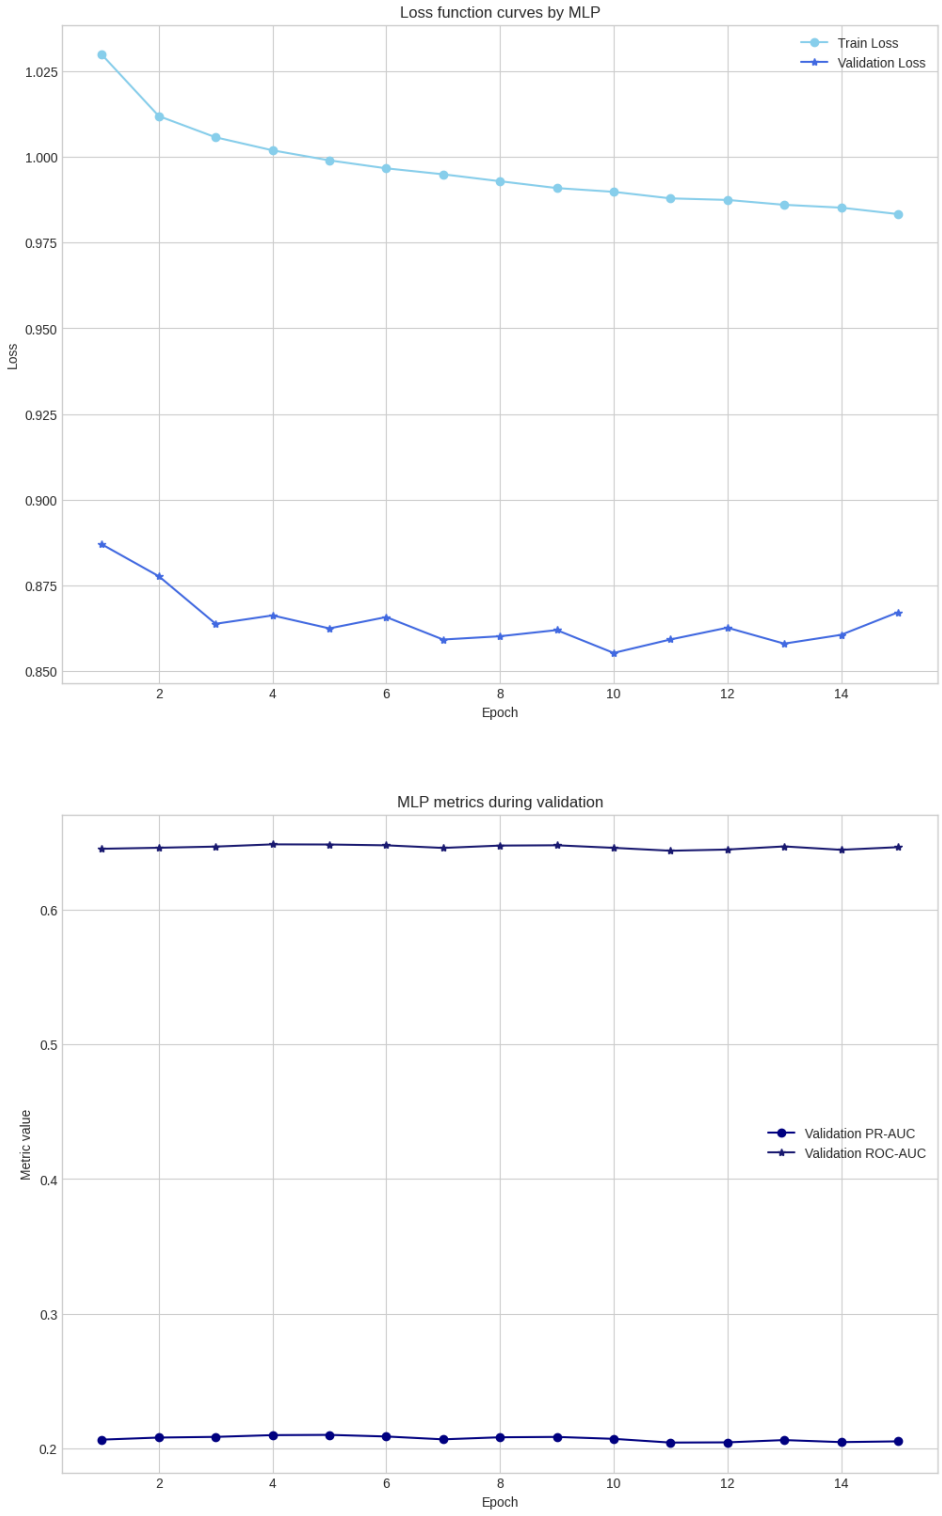


Рис. 7 – Обучение MLP, динамика loss и validation-метрик по эпохам

Conclusion

На этапе CV LightGBM и CatBoost были лучшими бустинговыми моделями, однако их преимущество сохранилось лишь частично на будущем временном периоде.

На test лучшую PR-AUC показал LGBM с подобранными параметрами (0.2608), практически наравне с Logistic Regression (0.2602), LGBM получил лучший ROC-AUC (0.61965)

Stacking и blending не улучшили результат на независимой тестовой выборке, несмотря на небольшое улучшение на OOF-предсказаниях.

MLP работала устойчиво, но уступила классическим моделям; лучший validation PR-AUC составил 0.2103 с учётом доли положительного класса на этой выборке в 0.135.

С учётом стоимости FN выше стоимости FP полезно рассматривать threshold как отдельный бизнес-параметр, а не фиксировать его автоматически на уровне 0.5, в этой работе он был подобран на основе стекинга LGBM и CatBoost с подобранными гиперпараметрами через Optuna. Он составил 0.1561.

Логистическая регрессия позволила уменьшить финансовые потери на 25.26% с учётом сдвинутого порога, LGBM же уменьшил число трат на 23.68%.